Beispieldokument für RAG (Retrieval-Augmented Generation)

Dieses Dokument (**sample_document.pdf**) dient als Platzhalter und Testdatei für das RAG-KnowledgeBase Projekt.

1. Einführung in RAG

Retrieval-Augmented Generation (RAG) ist eine Technik, die die Fähigkeiten von großen Sprachmodellen (LLMs) mit einer externen Wissensdatenbank kombiniert. Dadurch kann das Modell präzisere und aktuellere Antworten liefern, die auf spezifischen, hochgeladenen Dokumenten basieren, anstatt sich nur auf sein allgemeines Trainingswissen zu verlassen.

2. Die Funktionsweise der Ingestion

Das Skript `ingest.py` führt in der Regel folgende Schritte aus:

- **Laden:** Es nutzt einen Document Loader (wie den PyPDFLoader), um den Text aus diesem PDF zu extrahieren.
- **Splitten:** Der Text wird in kleinere Abschnitte (Chunks) unterteilt.
- **Embedding:** Diese Chunks werden in mathematische Vektoren (Embeddings) umgewandelt.
- **Speichern:** Die Vektoren werden in einer Vektordatenbank (z.B. Chroma DB) gespeichert, damit sie später durchsucht werden können.

3. Test erfolgreich

Wenn du diesen Text in den Ergebnissen deines Chatbots siehst, bedeutet das, dass das Einlesen der PDF und die Erstellung der Chroma_db erfolgreich war!